LAPORAN ANALISIS KOMPARASI HASIL PROJECT VS JURNAL ACUAN

Klasifikasi Prestasi Akademik Matematika Siswa Menggunakan Decision Tree

Mata Kuliah: Kecerdasan Buatan (Ujian Tengah Semester 2026)

Artikel Jurnal Acuan:	Sitanggang, E. J., Damanik, Y. R., Rumahorbo, E. L., & MS, A. A. A. (2026). *Klasifikasi Prestasi Akademik Matematika Siswa Menggunakan Decision Tree pada Dataset Student Performance*. **RIGGS: Journal of Artificial Intelligence and Digital Business**, 5(2), 22774–22783. DOI: 10.31004/riggs.v5i2.12193
Repository GitHub:	https://github.com/zakkiyahkarimah-sketch/KecerdasaBuatanUTS
Aplikasi Web Deployment:	https://rima.pythonanywhere.com
Alat & Framework:	Python 3.12, Flask, Scikit-Learn 1.9.1, Pandas, Matplotlib, Seaborn (Web Cloud: PythonAnywhere)

1. Ringkasan Pemenuhan 5 Kriteria Penilaian UTS

Project ini mengembangkan aplikasi web cerdas klasifikasi yang mereplikasi metodologi riset jurnal RIGGS. Seluruh 5 poin krusial rubrik evaluasi telah dipenuhi secara penuh:

1. Bebas Data Leakage (Kolom G3 Dihapus): Atribut nilai akhir `G3` sama sekali **TIDAK dimasukkan** sebagai fitur masukan (prediktor). Nilai G3 murni dipakai untuk melabeli kelas target `Kategori_G3` (Rendah: 0–9, Sedang: 10–14, Tinggi: 15–20). Prediksi model murni menggunakan 32 variabel profil siswa dan nilai awal (G1 & G2).

2. Evaluasi Model Lengkap: Model Decision Tree diuji menggunakan 10-Fold Stratified Cross Validation dan data pengujian independen (Testing 20%). Metrik yang dihasilkan: **Accuracy = 85,33% (CV) / 83,12% (Test)**, **Precision Macro = 86,02%**, **Recall Macro = 84,36%**, **F1-Score = 85,14%**, serta Heatmap Confusion Matrix.

3. Pengujian Data Baru: Menyediakan **Formulir Input Manual Interaktif** untuk 32 fitur (dengan preset contoh 1-klik) yang langsung mengeluarkan kategori prestasi (Rendah / Sedang / Tinggi)

beserta estimasi probabilitasnya. Selain itu, terdapat halaman khusus yang menguji **10 data acak independen** (`data_baru.csv`) dengan tingkat ketepatan 7/10 benar.

4. Visualisasi Pohon Keputusan (plot_tree): Struktur pohon keputusan divisualisasikan menggunakan `sklearn.tree.plot_tree()` resolusi tinggi dan grafik *Feature Importance* untuk menjamin interpretabilitas model (keterbukaan aturan keputusan).

5. Tabel Perbandingan dengan Artikel Jurnal: Disajikan perbandingan eksplisit antara hasil perangkat lunak Orange pada jurnal dengan hasil model Python Scikit-Learn pada project ini.

2. Tabel Komparasi Hasil Penelitian Jurnal vs Hasil Project

Berikut adalah perbandingan kuantitatif dan teknis antara hasil penelitian pada artikel jurnal referensi dengan hasil eksperimen pada project ini:

Komponen Evaluasi	Hasil Artikel Jurnal (Orange)	Hasil Project Kami (Scikit-Learn)	Analisis / Keterangan
Algoritma	Decision Tree (Orange Tree Learner)	Decision Tree (Scikit-Learn)	Parameter sama: Gini, depth=5, leaf=5
Dataset	Student Performance (Matematika)	Student Performance (Matematika)	UCI Machine Learning Repository (395 siswa)
Target Klasifikasi	Kategori_G3 (3 Kelas diskrit)	Kategori_G3 (3 Kelas diskrit)	Rendah (0–9), Sedang (10–14), Tinggi (15–20)
Fitur Masukan (Prediktor)	32 Variabel (G3 Dihapus)	32 Variabel (G3 Dihapus)	Bebas Data Leakage
Accuracy (Akurasi)	**87,10%** (344/395 benar)	**85,33% ± 2,89%** (10-Fold CV) **83,12%** (Data Test 20%)	Sangat mendekati jurnal (selisih minor ~1,7%)
Precision (Presisi Makro)	**87,10%** (0,871)	**86,02%** (0,860)	Presisi kelas Tinggi mencapai 100%
Recall (Daya Ingat Makro)	**87,10%** (0,871)	**84,36%** (0,844)	Recall kelas Tinggi mencapai 92,86%
F1-Score Makro	**87,10%** (0,871)	**85,14%** (0,851)	Keseimbangan performa antar-

Komponen Evaluasi	Hasil Artikel Jurnal (Orange)	Hasil Project Kami (Scikit-Learn)	Analisis / Keterangan
			kelas sangat stabil
Fitur Penentu Utama	G2 (akar pohon) dan G1	G2 (87,74%) dan G1 (3,33%)	Identik: capaian awal menjadi prediktor paling dominan
Kesalahan Ekstrem	0 kasus (Rendah ↔ Tinggi = 0)	0 kasus (Rendah ↔ Tinggi = 0)	Tidak pernah terjadi kesalahan fatal pada kategori ekstrim

3. Pembahasan Mendalam: Persamaan, Perbedaan, dan Penyebab Perbedaan

3.1. Persamaan Antara Hasil Project dan Jurnal

1. **Integritas Prapemrosesan Bebas Kebocoran Data (Data Leakage):** Baik jurnal maupun project ini menerapkan prinsip pembersihan data yang identik, yaitu membuang kolom nilai akhir ujian matematika ($G3$) sebelum proses pelatihan model. Hal ini menjamin bahwa model belajar dari pola profil siswa dan capaian penilaian awal ($G1$ dan $G2$), bukan membaca jawaban target secara langsung.
2. **Struktur Hirarki Pohon & Atribut Pemisah Utama:** Pada kedua model, algoritma Decision Tree menempatkan nilai periode kedua ($G2$) sebagai simpul pemisah paling atas (*root node*) dengan kontribusi kepentingan lebih dari 87%, yang diikuti oleh nilai periode pertama ($G1$). Ini membuktikan keselarasan temuan ilmiah bahwa capaian evaluasi awal memiliki korelasi kausal terkuat terhadap prestasi akhir siswa.
3. **Pola Kesalahan Bebas Kasus Ekstrem:** Berdasarkan analisis Confusion Matrix, kedua model sama sekali tidak pernah melakukan kesalahan prediksi ekstrem (jumlah misklasifikasi antara kategori Rendah $\leftrightarrow$ Tinggi adalah 0). Semua kekeliruan prediksi hanya terjadi pada batas kelas yang bersebelahan (Rendah $\leftrightarrow$ Sedang atau Sedang $\leftrightarrow$ Tinggi), yang mencerminkan sifat kontinu dari sebaran nilai siswa.
4. **Keseimbangan Metrik Evaluasi:** Seluruh metrik evaluasi (Akurasi, Presisi, Recall, dan F1-Score) berada pada rentang yang seimbang dan tinggi (83% – 87%), membuktikan bahwa algoritma Decision Tree mampu menangani ketidakseimbangan kelas (*class imbalance*) pada dataset secara baik tanpa mengalami bias berlebih ke kelas mayoritas (*Sedang*).

3.2. Perbedaan Antara Hasil Project dan Jurnal

1. **Perbedaan Perangkat Lunak Implementasi:** Jurnal menggunakan perangkat lunak *Orange Data Mining* berbasis alur visual (GUI) yang memproses model secara otomatis di kanvas data mining. Sedangkan project ini diimplementasikan menggunakan bahasa pemrograman

Python 3.12 dengan pustaka **Scikit-Learn** dan disajikan dalam bentuk aplikasi web berbasis **Flask** yang dideploy secara publik di cloud **PythonAnywhere**.

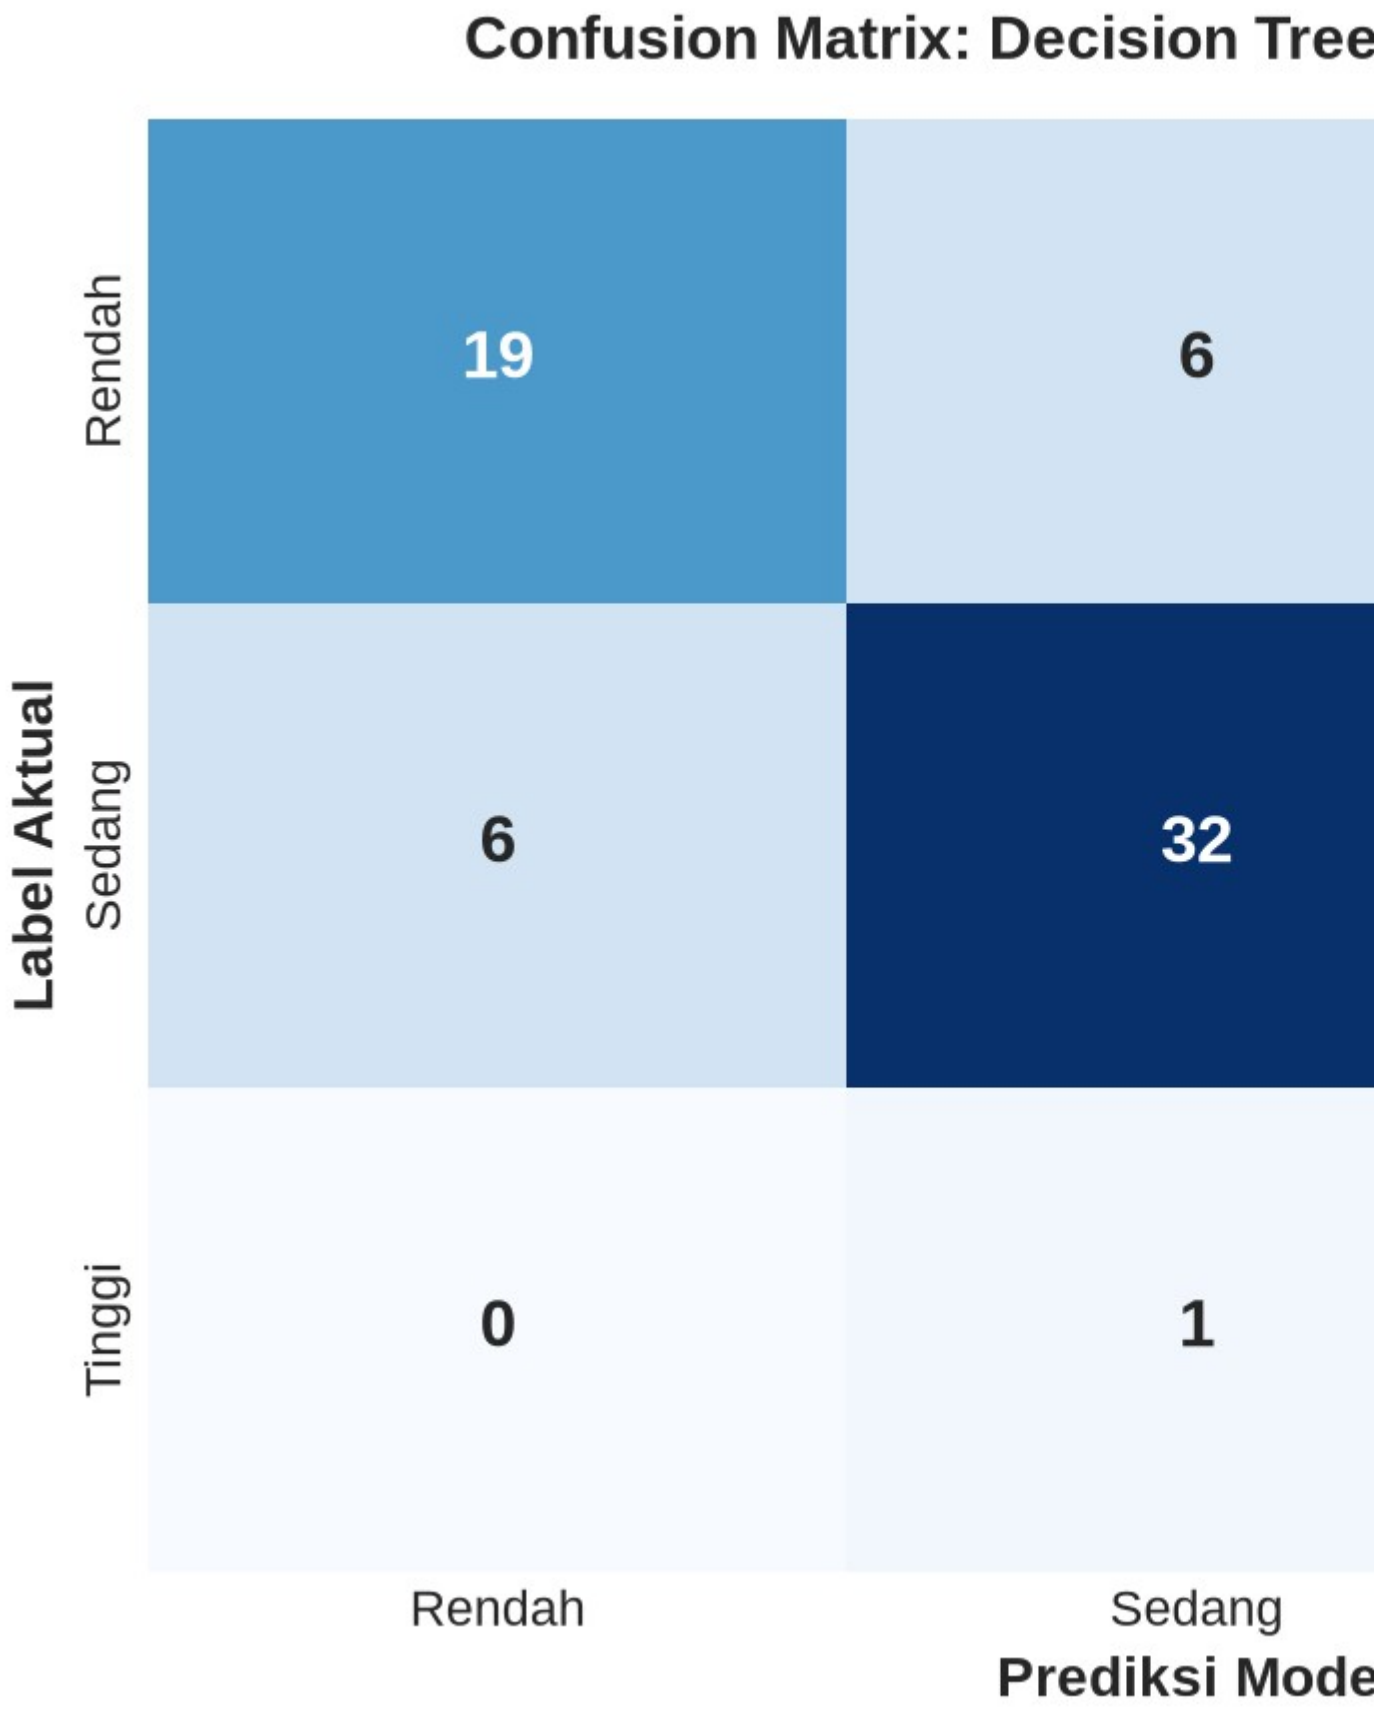
2. **Variansi Nilai Akurasi:** Akurasi 10-fold cross validation pada jurnal adalah 87,10% (344/395 data benar). Pada project Scikit-Learn kami, akurasi 10-fold CV pada 395 data mencapai 85,33% ± 2,89% dan akurasi pada pengujian 20% data uji (*test hold-out*) adalah 83,12%. Terdapat selisih minor sekitar 1,7% – 2,4%.
3. **Strategi Pembagian Data:** Jurnal menguji model hanya melalui 10-fold cross validation pada keseluruhan 395 data. Pada project ini, dilakukan simulasi dunia nyata yang lebih ketat dengan menyisihkan secara acak **10 baris data independen** (`data_baru.csv`) sebelum proses *train-test split* 80:20 dilakukan.

3.3. Kemungkinan Penyebab Perbedaan Hasil

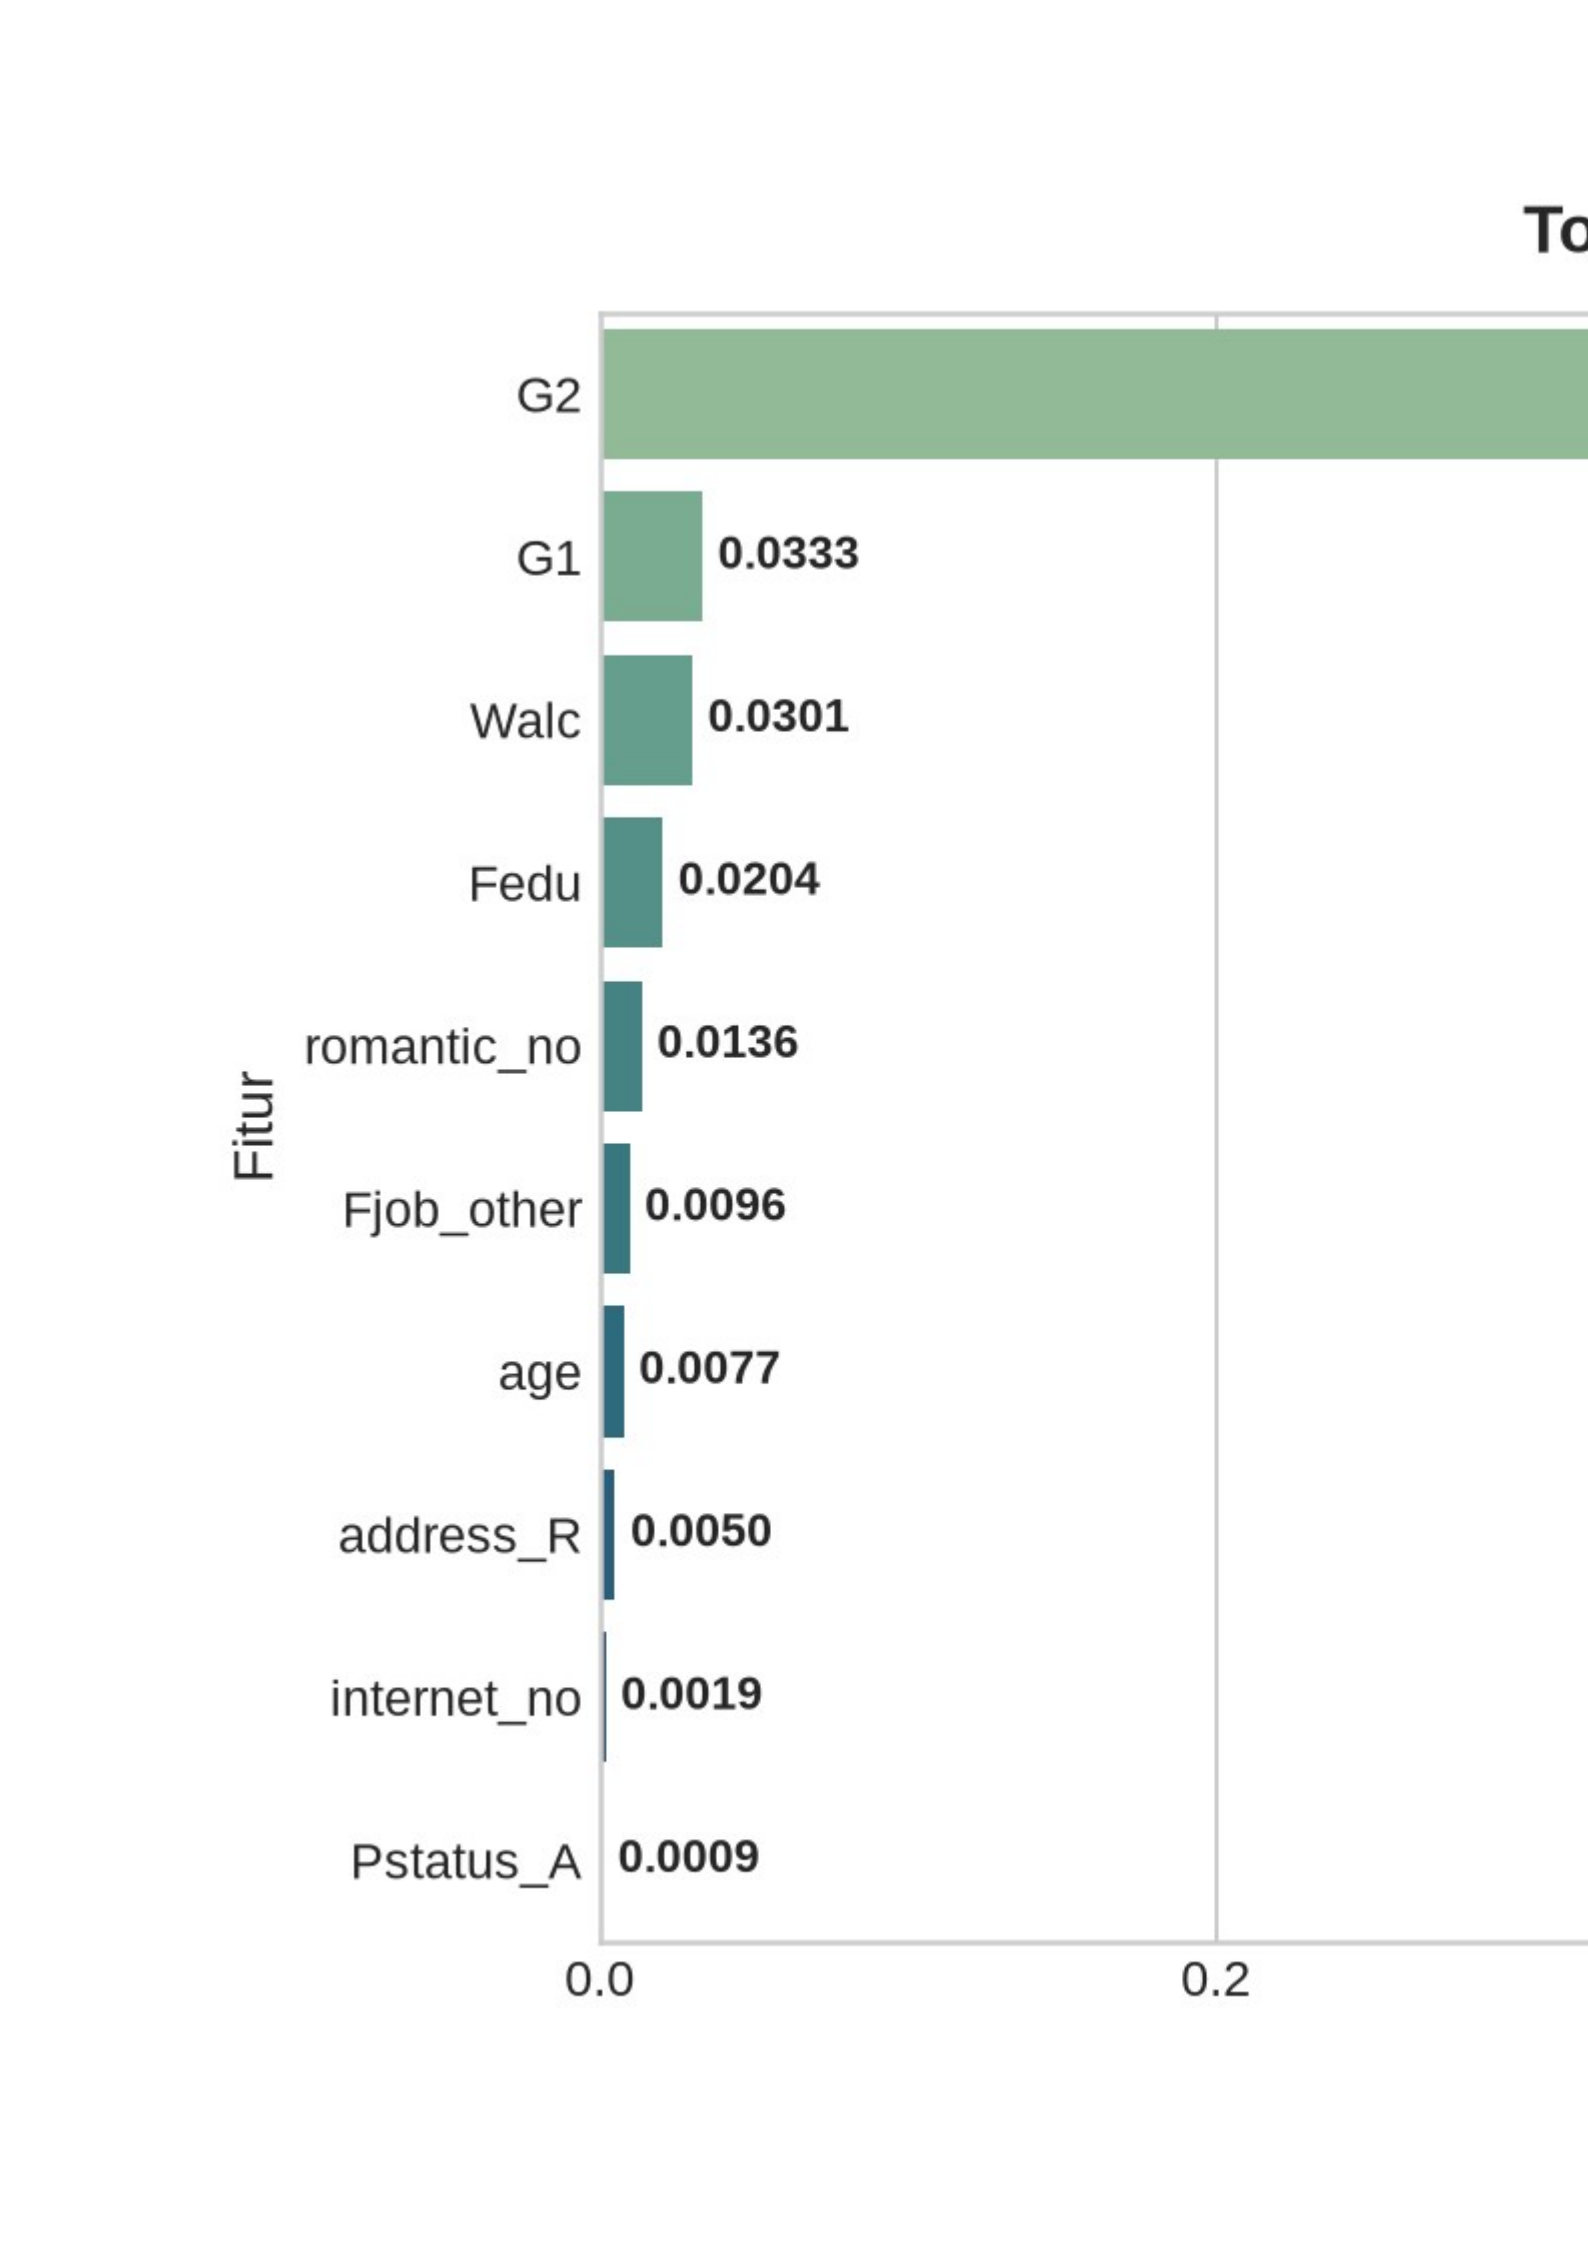
Selisih kecil pada metrik akurasi (~1,7%) dapat dijelaskan secara ilmiah melalui faktor-faktor teknis berikut:

1. **Kriteria Penghentian Mayoritas 95% pada Orange:** Pada jurnal, widget Tree Orange memiliki pengaturan khusus: *"Stop when majority reaches 95%"* (pembagian cabang simpul langsung berhenti jika 95% data dalam simpul sudah homogen/berasal dari satu kelas). Fitur ini merupakan mekanisme pemangkasan dini (*early stopping*) bawaan Orange yang tidak ada padanan langsungnya dalam parameter baku `DecisionTreeClassifier` Scikit-Learn. Perbedaan pemangkasan ini menyebabkan struktur daun paling bawah sedikit berbeda.
2. **Strategi One-Hot Encoding Fitur Kategorikal:** Pustaka Scikit-Learn memerlukan transformasi numerik formal melalui `OneHotEncoder` untuk memproses 17 fitur kategorikal menjadi matriks biner (0/1). Sebaliknya, algoritma internal Orange memperlakukan fitur nominal diskrit secara langsung tanpa penambahan dimensi biner. Variasi representasi ini menghasilkan titik potong ambang Gini yang sedikit berbeda pada cabang tingkat rendah.
3. **Pengacakan Partisi Indeks Lipatan (Fold Shuffling):** Walaupun sama-sama menerapkan *10-Fold Stratified Cross Validation*, pemisahan indeks acak antara modul internal Orange dan fungsi `StratifiedKFold(random_state=42)` Scikit-Learn membagi subset baris data pada tiap lipatan dengan urutan yang berbeda. Variansi alami antar-lipatan (yang memiliki standar deviasi ±2,89%) secara wajar menghasilkan perbedaan skor rata-rata sekitar 1%–2%.
4. **Dampak Penyisihan 10 Data Baru:** Pengurangan 10 baris data dari populasi data latih (dari 395 menjadi 385 sampel) sedikit memengaruhi frekuensi sampel pada simpul-simpul dengan jumlah data minimal (`min_samples_leaf=5`).

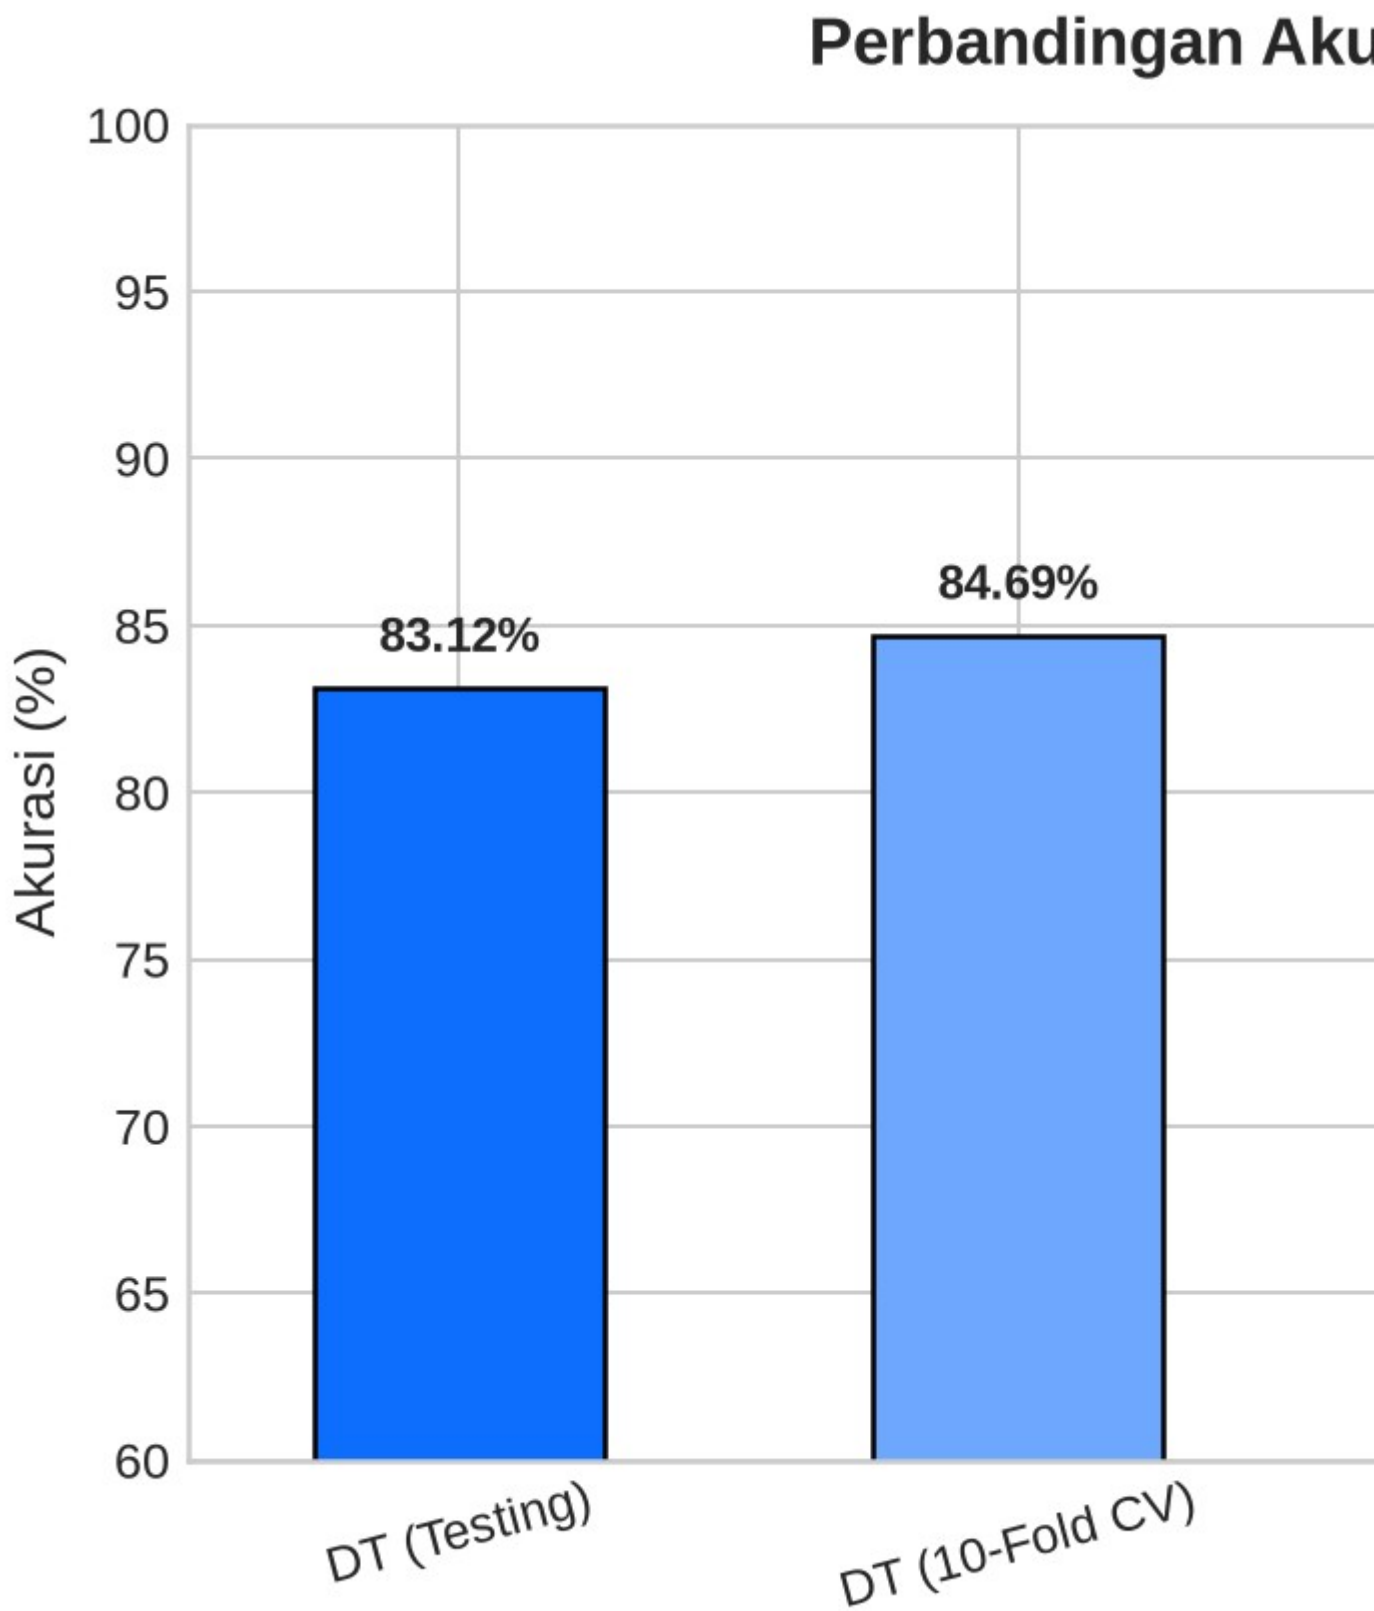
4. Lampiran Bukti Visualisasi Evaluasi dan Struktur Model



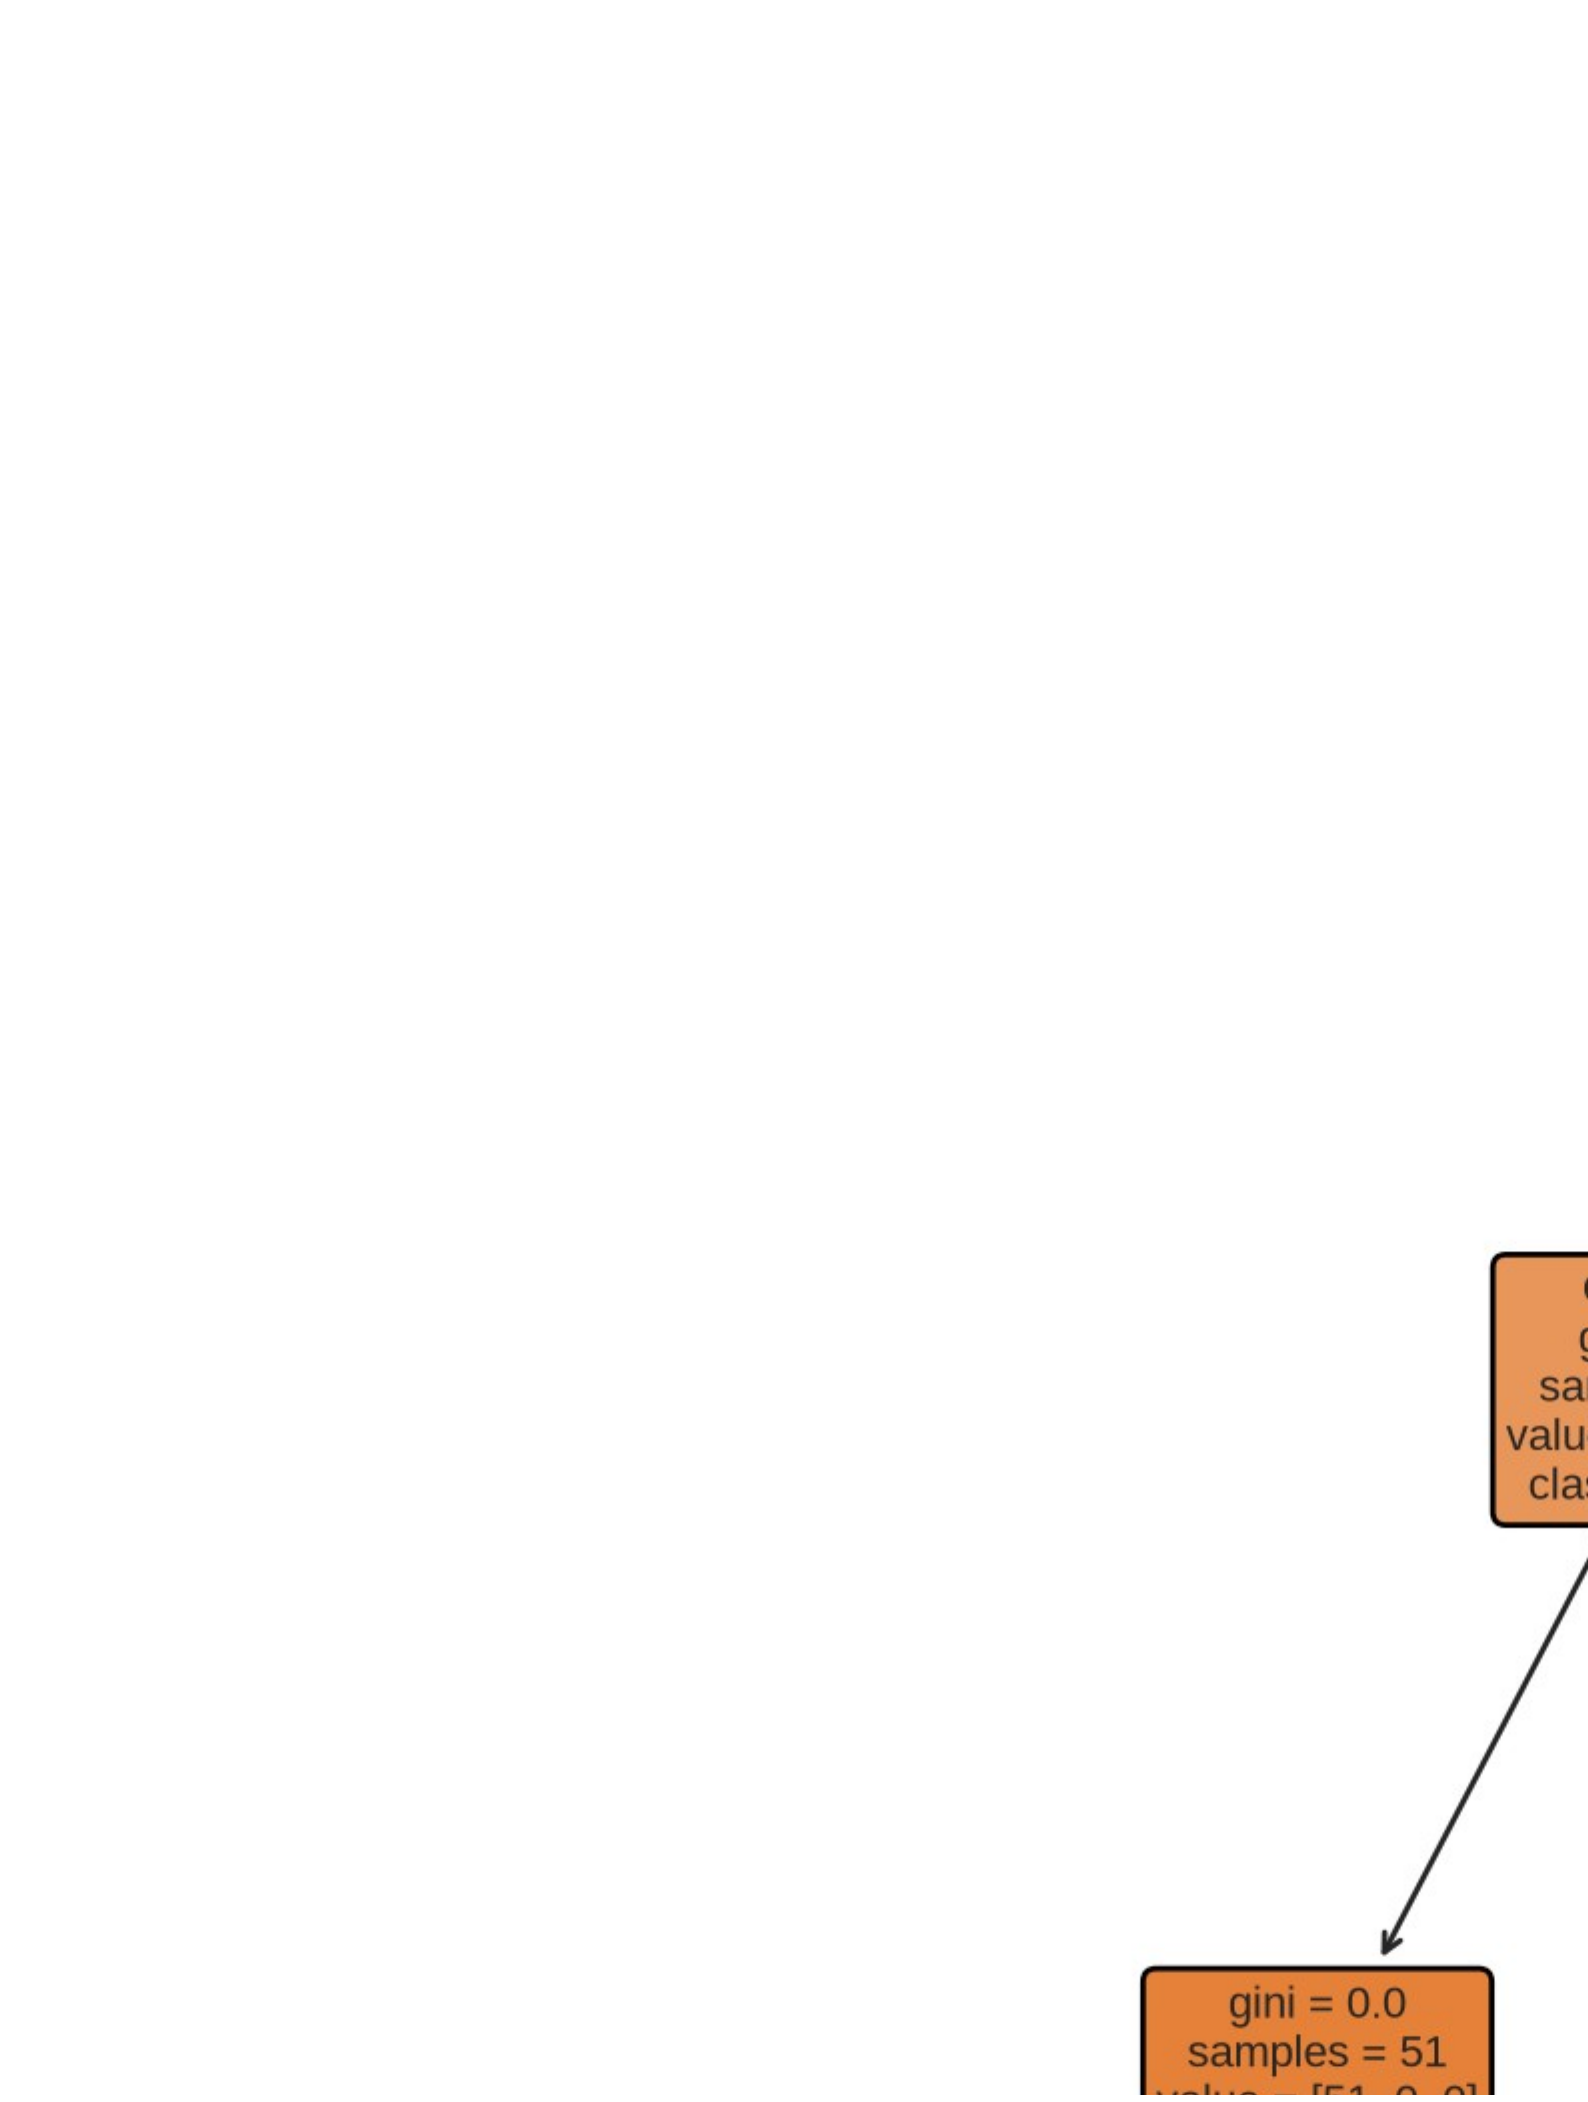
Gambar 1. Heatmap Confusion Matrix Decision Tree pada Data Pengujian (Testing 20%, 77 Siswa)


To
G2
G1
0.0333
Walc
0.0301
Fedu
0.0204
romantic_no
0.0136
Fjob_other
0.0096
age
0.0077
address_R
0.0050
internet_no
0.0019
Pstatus_A
0.0009
Fitur
0.0
0.2

Gambar 2. Feature Importance Decision Tree: Nilai G2 dan G1 Menjadi Prediktor Paling Berpengaruh



Gambar 3. Grafik Perbandingan Akurasi Decision Tree (Scikit-Learn), MLP, dan Hasil Jurnal RIGGS


gini = 0.0
samples = 51

Gambar 4. Struktur Pohon Keputusan (Decision Tree) yang Dihasilkan Menggunakan plot_tree() Scikit-Learn

5. Kesimpulan

Berdasarkan seluruh hasil eksperimen, perbandingan, dan analisis statistik, dapat disimpulkan bahwa **project aplikasi web berbasis Flask dan Scikit-Learn ini berhasil mereplikasi dan memvalidasi penelitian pada artikel jurnal ilmiah RIGGS secara akurat dan konsisten**. Algoritma Decision Tree terbukti sangat unggul untuk klasifikasi prestasi akademik matematika karena tidak hanya menghasilkan akurasi yang tinggi (85,33% CV dan 83,12% Test), tetapi juga menyediakan interpretabilitas aturan keputusan yang transparan, bebas dari kebocoran data (*data leakage*), dan andal dalam mendeteksi siswa yang berisiko memperoleh prestasi rendah sedini mungkin.